

工学硕士学位论文

基于时频分析的音乐可视化研究

全夏庆

哈尔滨理工大学

2023 年 3 月

国内图书分类号: TN912.16

工学硕士学位论文

基于时频分析的音乐可视化研究

硕 士 研 究 生: 全夏庆

导 师: 张宏

申请学位级别: 工学硕士

学 科、专 业: 软件工程

所 在 单 位: 计算机科学与技术学院

答 辩 日 期: 2023 年 3 月

授予学位单位: 哈尔滨理工大学

Classified Index:TN912.16

Dissertation for the Master Degree in Engineering

Research on Music Visualization Based on Time-Frequency Analysis

Candidate:	Quan Xiaqing
Supervisor:	Zhang Hong
Academic Degree Applied for:	Master of Engineering
Specialty:	Software Engineering
Date of Oral Examination:	March, 2023
University:	Harbin University of Science and Technology

基于时频分析的音乐可视化研究

摘要

音乐在人类发展中发挥着重要的作用，尽管音乐是一种听觉现象，但也可以通过视觉上的展示以可视化的方式来表达音乐，并且广泛应用于实际需求中。对于可视化的方案上本文首选了对视觉冲击力最大的色彩，并综合运用心理学、音频信号处理技术以及深度学习等技术，对音乐的属性以及特性进行了时域和频域上的可视化分析，并通过建立的音乐与色彩的关系模型，研制了在嵌入式平台以及 PC 机上的色彩音乐可视化系统。

在嵌入式平台上，本文采用音频信号处理技术对音频进行了实时采样和分析，基于时频分析理论，采用改进的算法识别出了音乐的音级，并通过建立的音级与色彩之间的关系，将播放的音乐通过脉冲宽度调制（Pulse Width Modulation, PWM）驱动 RGB-LED 混光模块实时地匹配出了相应的色彩，展现出了音与色彩的可视化。针对嵌入式系统上计算能力有限的缺陷，以及为了确保各个模块间的稳定通信，音乐的流畅播放与色彩的实时性，通过统筹考虑系统的工作调度和时序安排，设计了双处理器系统。并在此基础上完成了对每个模块的搭建和设计以及功能上的调试。最后通过大量的实验测试与分析，确保了本系统的实时性以及对算法处理上的可靠性，并达到了预期的效果。由于是在嵌入式平台上进行的开发与设计，因此本系统有着便携性、实时性以及可移植性的显著优点，对于城市景观、车载氛围灯以及舞台灯光等领域内具有较大的实际应用价值。

不仅如此，音乐在心理治疗等方面也有着非常广泛的前景，因此本文对音乐进行了进一步的分析，不在局限于音乐的低级特征，进而分析音乐的高级特征——情感。由于情感的复杂性、主观性以及模糊性，本文通过 PC 机展开了实验与分析。对于音乐的情感，本文基于 Valence-Arousal 维度的情感模型，采用深度学习技术，通过分析不同角度下音乐的时频特征，提出了一种基于时频图像的 CLSA 模型，并识别出了音乐的情感，进而输出了 Valence-Arousal 维度的二维空间中的值，并通过建立的情感空间与色彩空间之间的映射关系，将播放的音乐通过训练好的模型实时地匹配出了相应的色彩，达到了音乐的情感与色彩的匹配，展现出了音乐情感与色彩之间的可视化效果，为日后的音乐治疗等领域提供了较大的应用价值。

关键词 色彩音乐；嵌入式系统；音乐情感识别；深度学习

Research on Music Visualization Based on Time-Frequency Analysis

Abstract

Music plays an important role in human development. Although music is an auditory phenomenon, it can also be expressed visually and is widely used in practical needs. In this paper, we have chosen the most visually appealing color for visualization, and we have used psychology, audio signal processing technology and deep learning technology to analyze the properties and characteristics of music in the time and frequency domains, and we have developed a color music visualization system on embedded platform and PCs by establishing the relationship model between music and color.

On the embedded platform, this paper uses audio signal processing technology to sample and analyze the audio in real time, and based on the theory of time-frequency analysis, an improved algorithm is used to identify the sound level of the music, and through the established relationship between the sound level and the color, the played music is driven by Pulse Width Modulation (PWM) to match the RGB-LED mixing module in real time, showing the visualization of sound and color. The corresponding colors are matched in real time by the pulse width modulation (PWM) driven RGB-LED mixing module, showing the visualization of sound and color. In order to ensure stable communication between modules and smooth playback of music and color in real time, a dual-processor system was designed by considering the work scheduling and timing arrangement of the system. On this basis, we have completed the construction and design of each module as well as the functional debugging. Finally, through extensive experimental testing and analysis, the real-time performance of the system and the reliability of the algorithm processing are ensured, and the expected results are achieved. Since the system is developed and designed on an embedded platform, it has the significant advantages of portability, real-time and portability, and is of great practical application value in the fields of urban landscape, car ambient light and stage lighting.

In addition, music has a wide range of prospects in psychotherapy and other areas, so this paper analyzes music further, not only in terms of its lower characteristics, but

also in terms of its higher characteristics - emotions. Due to the complexity, subjectivity, and ambiguity of emotion, this paper conducts experiments and analyses through a PC. For the emotion of music, this paper proposes a CLSA model based on time-frequency images by analyzing the time-frequency features of music in different angles based on the emotion model of Valence-Arousal dimension, and identifies the emotion of music, and then outputs the values in the two-dimensional space of Valence-Arousal dimension, and identifies the emotion of music by the established mapping relationship between emotion space and color space, the played music is matched with the corresponding color in real time by the trained model, which achieves the matching of emotion and color of music and shows the visualization effect between emotion and color of music, which provides a greater application value for the future music therapy and other fields.

Keywords color music; embedded system; music emotion recognition; deep learning

目 录

第 1 章 绪论.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.3 本文的主要研究内容.....	4
1.4 结构安排.....	5
第 2 章 相关理论背景	6
2.1 乐音理论及可视化分析.....	6
2.2 音频信号的可视化分析.....	8
2.2.1 音频信号的预处理.....	8
2.2.2 时域分析	9
2.2.3 频域分析	11
2.2.4 时频分析	13
2.3 本章小结.....	17
第 3 章 基于时频分析的音乐可视化实验平台的设计	18
3.1 需求分析.....	18
3.2 硬件系统总体设计.....	18
3.2.1 双处理器电路设计	19
3.3 音频播放程序设计.....	21
3.3.1 音频读取模块设计	21
3.3.2 音频采样模块设计	22
3.3.3 混光模块设计	24
3.4 其他模块设计.....	26
3.4.1 键盘模块设计	26
3.4.2 LCD 显示模块设计	26
3.5 本章小结.....	26
第 4 章 基于音级识别的音乐可视化系统	27
4.1 算法分析与设计.....	27
4.1.1 快速傅里叶算法.....	27
4.1.2 基于时频分析的改进的音级识别算法	28
4.2 系统测试.....	30
4.2.1 音频文件读取及播放测试.....	31
4.2.2 音频采样及频谱分析测试.....	31
4.2.3 音级识别测试.....	35
4.2.4 基于音级的可视化展示.....	35

4.3 本章小结.....	36
第 5 章 基于情感识别的音乐可视化系统	37
5.1 数据集分析.....	37
5.2 基于时频图的模型构建.....	38
5.2.1 卷积神经网络.....	38
5.2.2 循环神经网络.....	39
5.2.3 自注意力机制.....	41
5.2.4 改进的组合神经网络.....	42
5.3 实验与分析.....	43
5.3.1 音乐情感识别的评价指标.....	43
5.3.2 音频数据的时频处理.....	44
5.3.3 对比试验结果与分析.....	45
5.3.4 音乐情感的可视化设计与展示.....	46
5.4 本章小结.....	49
结论.....	50
参考文献.....	52

第1章 绪 论

1.1 课题背景及研究意义

音乐的可视化是指将数据从听觉空间转换到视觉空间，通过静态的图像或动态的动画来表达音乐的一种技术。在内容上可视化技术可以反映其音乐的内容，如节奏、音高、旋律等低层特征到语义、情感等高层特征。音乐可视化^[1]着重于听觉和视觉上的互动，为理解、分析和比较音乐艺术作品形态的表现力和内外部结构提供一种直观地呈现视觉的技术。音乐可视化是以音乐为载体，视觉为核心，通过画面、影像来诠释音乐。它是一种创造性的实践，是对特定声音特征的可视化表示，它不会把眼睛和耳朵分开，以一种更有意义，更有趣的方式去了解音乐，并可以有效地弥补音乐的抽象性。寻找音乐和视觉之间的对应关系，并利用这些来建立一种新的模式，实际上是一种新的艺术形式。全球最大的娱乐及媒体企业——华特迪斯尼公司制作了《幻想曲》系列动画，成功地将音乐这门抽象艺术带入了视听结合的全新境界，为音乐可视化研究做出了跨时代性的尝试。由此可见，在未来的动画制造领域内，音乐可视化将成为音乐美学思想的一种重要手段。音乐可以创造非凡的氛围，并且可以勾起人们不一样的情绪。比如在一些重要的电影场景中，可以通过合适的背景音乐表达人物的内心世界、烘托气氛，同时带动观众的情绪并深入到电影的情景之中，感受影片所传达的内涵。同样的道理，在歌手们的现场演奏会中，他们不仅仅是演奏现场歌曲，更多的是一种视觉上的体验。舞台上的音乐家变成了演员，用他或用他的乐器来传达情感。然而这些视觉特征并没有在歌曲的数字音频中体现出来。由此如果能够提供一种创新的音乐可视化方法，便可以让听众更有效地沉浸在音乐中，提高对音乐的体验感。

如今随着技术的进步和不同的应用需求，在以一切信息可视化的视觉工业时代里，音乐的可视化已被广泛地应用于实际需求中，基于交互的声音可视化已经从纯粹的艺术领域发展到更实用的方向，例如在辅助医疗、娱乐、教育^[2]和商业场景，包括音乐会、商业广告、音乐课堂等。互联网的普及和高质量的音频格式的使用，极大地促进了数字音乐库的增长，日常生活中的各个角落都可以接触到音乐，如购物、吃饭、逛街、锻炼、驾驶等。在不同的场景听到的音乐也会有差别，从文献[3]中可知在咖啡厅或者服装店里如果能够 provide 适合相关商店的音乐就可以极大地增加销售额进而产生积极的影响。因此对于音乐风

格的选择和检索^[4]上可视化技术也有一定的应用价值。随着社会越来越趋向于智能化的方向发展,音乐可视化的这种交互形式在未来的实际应用中将会有很大的发展空间^[5]。

1.2 国内外研究现状

随着可视化和特征提取技术的发展,目前对音乐可视化的研究主要集中在音乐与视觉之间的转换关系以及相关实现技术的理论研究上。音乐可视化的想法是始于古希腊的数学家、哲学家毕达哥拉斯^[6, 7]。他研究了音阶,发现了音符频率之间的比率关系。这些数学关系比扩展到视觉世界,扩展到建筑和雕像,推动了到文艺复兴时期^[8]欧洲和伊斯兰的艺术发展。18 世纪,牛顿提出了一种颜色与音符的映射关系,这引起了人们的关注,且越来越多的研究^[9, 10]发现了音乐与色彩之间的联系。20 世纪初,随着光学和电子技术的进步,开始出现了色彩乐器,也为之后的音乐可视化奠定了一定的基础。随着数字计算机技术的发展,无需机械和电气的设备就可以实现视觉元素和声音元素之间的灵活转换。对于音乐可视化,目前的研究主要是集中在以下两个方面:一是强调在视觉上的呈现;二是在音乐结构上和信息上的体现,使得更有效地理解和学习音乐本身。

1997 年, Sean M. Smith^[11]等人为解决乐谱的复杂性,提出了一种通过颜色和三维空间来可视化音乐的方法,将音乐数据映射到三维空间中。通过定义单个音调映射函数和音乐中乐器的映射函数来实现可视化。在可视化序列中通过球体的半径大小来显示音符的音量,通过不同的颜色来区分音乐中不同的乐器。2005 年, Morchen F^[12]等人提出了基于感知距离的音乐数据集合的可视化方法。该方法使用数据挖掘技术,在短时窗口上的原始音频数据中提取低级的音频特征,并将这些低级特征聚集并评估一大组时间和非时间统计数据,对不同音乐之间的感知距离进行了建模,形成了描述音乐的高级特征序列,并通过地形图提供了大型音乐集合的直观游览。李华^[13]等人提出了一种实时渲染的技术,通过不同风格的水彩画来可视化音乐。该技术是通过 alpha 通道实现的,并且为了能达到动态场景的仿真效果,借助了 Direct3D 技术,并达到了良好的效果。2008 年, Chin Han Chen^[14]等人提出了一种基于情感的音乐播放器,将照片与音乐同步进而实现音乐的可视化。对于照片的情感检测,是由多位用户从网络上收集的照片进行情感标注的,然后利用这些注释,提出了一种用于自动分类检测情感照片的贝叶斯分类方法。2010 年, Mahdieh Poostchi^[15]等人提

出了基于梳状滤波器和人类感知的松弛时间的音乐可视化方法,该方法通过不同的梳状滤波器(从 60bpm 到 240bpm)的滤波器组与不同风格的音乐信号进行卷积,再根据人类感知进行可视化。在每个区间中,提取频域中的速度,然后提取时域中的起始时间。对于相邻节拍之间的间隙,以 100 毫秒为单位区分成两部分。用第一个 50 毫秒将信号拉伸到零点,用第二个 50 毫秒将信号拉伸到下一个节拍开始的点,由此可通过连续的正弦信号来可视化音乐的节奏。2011 年,Anastasia Gumulia^[16]等人着重研究了音乐的速度感,并提出了一种可视化的方法。该方法对影响曲调快慢的因素——音符数和附点音符以一个固定的时间间隔提取出来,并通过各种不同的形状表现出来。2012 年,Michael Pouris^[17]等人开发了一种基于试听感官替代模型的音乐可视化系统。该系统通过将音乐转换成前注意视觉序列,其转换算法是基于定义转换原则和心理模型实现的。Takashi Maekaku^[18]等人则提出了一种基于旋律转换的音乐映射方法,对不同音乐作品之间的差异进行了可视化。该系统是利用马尔可夫模型^[19],采用多维缩放方法,在二维图形上显示了音乐之间的关系。2013 年,Joyce Horn Fonteles^[20]等人提出了一个简化的三维粒子系统和快速翻译算法,设计和实现了由古典音乐编排的实时动画粒子发射器喷泉。2014 年,Aurea Soriano^[21]等人提出了基于结构内容相似度的音乐集合可视化方法,该方法通过 MIDI 文件提取音频的和弦序列特征,并利用最小二乘得到特征向量在空间内的投影,并使用动态时间扭曲距离函数评估了特征相似性。2015 年,Jeeun Kim^[22]等人将捕捉的音乐成分以数据的形式记录下来,并通过视觉形式为听力障碍儿童显示了数据。Delfina Malandrino^[23]等人利用图形可视化技术来表示古典音乐的数据结构,并对音乐作品进行了谐波分析。2016 年,Yunli Lee^[24]等人提出了一种基于主题的交互式音乐播放器的设计方法,该方法提取音乐的低层特征并与不同的形状和颜色相对应上,在视觉上增强了音乐和用户之间的联系。2017 年,Xie Zhenyang^[25]等人提出了基于 MIDI 协议的多维复音可视化方法。该方法通过分析对 MIDI 每个通道的音符的多维复音,并基于人机识别在声音和图像上的结构相似性,提出了新的音乐可视化映射模型。2018 年,Takumi Takahashi^[26]等人提出了一种基于自动识别乐器的音乐可视化系统。该系统通过深度卷积神经网络对乐器进行识别,并通过不同的颜色来表示不同的乐器。2019 年,Michael Taenzer^[27]等人对源分离方法进行了研究,将音乐分解成各个部分,然后使用灯光跟随歌曲的歌声和乐器的旋律。韦岗^[28]等人设计了一种与 MIDI 相对应的乐谱——鸟然谱,实现了 MIDI 音乐的可视化表征。2020 年,LI WEI^[29]等人在音乐图形图像的基础上,结合 K-means 聚类、融合决策树等数理统计方

法，构建了一个基于图形图像和数理统计的音乐可视化模型。2021 年，Liu Xiahan^[30]提出了基于自适应粒子群算法和误差反向传播神经网络，并对不同风格的音乐进行了分类和迁移可视化。

1.3 本文的主要研究内容

本文针对音乐可视化的方案上首选色彩属性，通过分析色彩与音乐之间的关系，研制出了色彩音乐系统，从而达到音乐的可视化效果。对于如今的色彩音乐播放系统已被广泛的应用到了很多的场景，比如彩色音乐喷泉^[31, 32]、舞台灯光^[33-35]、车载氛围灯^[36]以及音乐心理治疗^[37]等，因此具有较大的实际研究意义。然而市面上的大多数彩色音乐播放系统给人带来的视觉效果却参差不齐，其主要的原因是因为绝大多数的色彩都是由不同的设计师通过对音乐与色彩之间的不同理解而制作出来的，不能达到实时匹配的效果，因此常常会出现视听不一致的现象。对此本文提出了一种基于音级识别的色彩音乐播放系统和基于情感识别的色彩音乐播放系统，从音乐的低级特征到高级特征，寻找出色彩与音乐之间相匹配的方案来试着解决以上问题，具体研究内容包括：

（1）从音乐理论基础出发，通过分析数字音乐信号以及光谱的特性，找出两种属性相对应的规律，把音乐属性映射到色彩属性上，进而将色彩与音乐进行相关联，为后续色彩与音乐的匹配奠定基础。通过音频信号处理技术，以可视化的方式对各种音乐进行时频分析，为后续的音级识别以及音乐的情感分析提供技术支持。

（2）对实验平台进行设计，通过分析找出合适的硬件并进行电路的设计以及搭建，其主要包含文件系统模块、音频解码模块、显示模块、RGB-LED 模块等，并且为了各个模块间的流畅性，以及音乐播放的同时确保色彩的实时性，通过统筹考虑系统的工作调度和时序安排下，设计开发双处理器系统。

（3）对于嵌入式平台的软件设计上，为了提高系统的可扩展性，通过模块化编程对各个功能模块进行设计与开发，进而在调试时可根据具体的组合进行实验。为了能够识别出音乐的有效频率特征，对现有的时频分析算法做出优化和改进，提出一种可以很好的适应在嵌入式系统的音级识别算法来识别出音乐的音级并映射到色彩属性上。最后对系统进行实际的测试并通过相应的分析和改进来达到预期的效果，实现音乐的可视化。

（4）基于情感识别的色彩音乐播放系统是在 PC 机上进行的实验，为了确保音乐中情感的准确性，本文基于 Valence-Arousal 维度情感模型，使用对音乐

情感做出量化的数据集，并在此基础上采用深度学习技术进行情感上的识别与分析。通过分析和研究不同的神经网络模型的特性以及适用场景，提出一种融合卷积长短期记忆神经网络和自注意力模型来识别出音乐的情感并输出二维空间中的值。对于可视化的展现上，采用科学的方法将情感与色彩进行相关联，并将输出的值映射到色彩空间上，在音乐播放的同时通过训练好的模型识别出音乐的情感并与色彩进行相匹配进而达到可视化的效果。

1.4 结构安排

本文针对音乐的可视化，以音乐的时域、频域以及时频域上的特性为基础，提出了基于音级与基于情感识别的音乐可视化系统，本文的章节安排具体如下：

第 1 章主要阐述本课题的背景及研究意义，并介绍了音乐可视化领域的国内外研究现状。

第 2 章主要介绍了相关的理论背景，包括乐音理论以及处理音频信号的理论基础。

第 3 章主要介绍了基于嵌入式实验平台的研究与设计，包括硬件系统的总体设计，音频播放的程序设计以及各个模块间的相互通信等，为后续的基于音级识别的音乐可视化系统提供了所需的实验平台。

第 4 章主要介绍了基于音级识别的音乐可视化系统，提出了一种改进的方法来识别音乐的音级，并通过匹配出相应的色彩来完成音乐的可视化展现。

第 5 章主要介绍了基于情感识别的音乐可视化系统，提出了改进的深度学习模型来预测情感，进而实现音乐情感到色彩的可视化展示。

第2章 相关理论背景

本章主要介绍了乐音的相关理论，并对音乐信号进行了时域和频域上的分析，为后续章节的音乐可视化研究奠定理论基础及技术支持。

2.1 乐音理论及可视化分析

音乐的可视化可以通过不同的形状、大小、布局、色彩、动画等方式来展现。不同的表现形式可以产生不同的心理感受。在图案的所有属性（面积、体积、颜色、形状）中，颜色给人的印象最直观、深刻、持久。并且特定颜色的感觉通常是相同的。从心理学的角度上分析也可以发现色彩与音乐的共同作用下会产生联觉^[38, 39]。联觉在心理学中被定义为从一种感觉中引起另一种感觉的心理活动。联觉涉及到多种感觉，其中视觉和听觉的联系就是一种视听联觉。由音乐的作用下所引起的色彩的心理感受^[40]就属于一种视听联觉，即一个人听到声音时会不由自主地联想到颜色，不存在因地域、民族或个人差异而产生重大的差异。结合文献[41]和文献[42]可以了解到通常在每首歌中会把较低的音调看成较暗的颜色，如蓝色、绿色、紫色、黑色等。相反较高的音调通常会被看成是较亮的颜色，如金色，亮粉色，银色等，如图 2-1 所示，通过色轮图可以直观的进行表示。此外，音调越高，通常会感到非常有趣，反之就越沉闷。




图 2-1 色彩与音调的色轮图

Fig. 2-1 Color wheel diagram of color and tone

从物理学的角度分析也可以得到色彩与音级上的类似关系。人耳能听到的声音频率范围大约是从 20Hz 到 20000Hz，在音乐上从低到高，大约包含 7 个八度。这里的八度是指在乐音中，相邻的音组中相同音名的两个音之间的音程关系。低八度音与高八度音之间的频率之比为 1: 2，并且它们听起来非常的相似。比如一个标准音 A^1 的频率是 440Hz，那么它的高八度 A^2 音的频率就是 880Hz。一个八度还可以均分为十二个全相等的半音，构成十二平均律，那么两个相邻的半音之间频率之比就是 $1: \sqrt[12]{2}$ 。音乐可以是任何形式的，和谐的音调组合听起来是悦耳的，不和谐的音调组合听起来是浑浊的，因此可以通过饱和色来表示和谐音，用灰色来表示不和谐的音调组合。而当频率之比为 2: 3 时，就会有所谓的“纯五度”的音关系。它是构成音乐中“调”的最基本的音程关系，也是一种完全的和谐音程。在十二平均律中由一个音向上数七个半音，便能得到纯五度的音。Sethares^[43]描述如果音乐的音程听起来是愉快或平静的，则他是辅音。一般辅音就是音乐中的八度和五度的音，通常被认为是悦耳的，而对于不和谐的音通常认为是粗糙和刺耳的。从这种音程关系中还可以推导出“色关系”。三原色中红色波长与蓝色波长的比值为 3: 2，这就意味着色彩也存在着所谓的“色关系”。通过这种关系法则，便可以推导出各种色相之间的关系。在这选择三原色之一的红色（670nm）作为主色进行推导。这里的红色就类似于音乐中的主音 C 音。然而人眼可感知的光的波长范围大约是从 380nm 到 780nm，通过这种色关系推导出来的色相会超出人眼可感知的波长范围。这时可以引入音乐中的八度规律关系，对色彩进行八度平移，再通过十二平均律的频率^[44]规则计算出与音调相对应的十二种色相的波长。

通过以上的数学推理分析，就可以从音乐中一个八度的十二个半音中推导出指定的十二种颜色，建立音符与色相之间的映射关系，如表 2-1 所示，其中 C 大调对应朱红，D 大调对应黄色，以此类推。

表 2-1 音与色相的对应关系

Table 2-1 The correspondence between tone and color

音名	频率(Hz)	色相名	波长(nm)
C	261.6	朱红	670
#C	277.2	橙	632
D	293.7	黄	596
#D	311.1	黄绿	562
E	329.6	绿	530

续表(2-1)

F	349.3	蓝绿	502
#F	370	蓝	473
G	392	紫蓝	447
#G	415.3	紫	422
A	440	紫红	397
#A	466.2	洋红	357
B	493.9	红	353

2.2 音频信号的可视化分析

音乐的本质就是一种物理波动现象，当空气分子通过某种振动开始运动时就会产生声音，人就会被自己的听觉器官所感知，并由此产生的气压变化随着时间的推移便可以产生连续信号，也就是说在实际生活中音乐都是以模拟信号的形式存在的，它的波形是连续变化的，而计算机只能处理离散信号，为了在有限的内存里表示连续的过程，需要将模拟信号按固定的频率进行采样然后通过量化将连续的信号转换为离散信号。其中采样的过程中为了使信号不丢失信息，根据奈奎斯特采样定理，采样频率必须不能小于模拟信号最大频率的两倍。最后在再通过不同的编码形式将音乐信号压缩成计算机可以处理的信号形式。常用的编码格式有 WAV，MP3，MIDI 等，其中 MP3 通过有损压缩技术减小了音频文件的大小，与其他音频格式比较时其占用的空间比较小，因此是一种很受欢迎的格式。

综上，对于音乐信号的处理离不开以下两个步骤，首先就是得到音乐信号的一般表示，这种表示可以是参数形式也可以是波形形式。然后就要对得到的信号进行变换，以便适用于研究某一特性，其基本流程如图 2-2 所示。

2.2.1 音频信号的预处理

在分析音频信号之前，为了提高数据质量首先需要对信号进行预处理，以便更有效地进行分析。首先可以通过预加重提高高频部分，使信号变得平坦。然后通过分帧，将 N 个采样点集合成一个观测单位，从长时间非稳定的序列中得到相对稳定的短序列，一帧的长度通常取 10~30ms。然而分帧时由于起始端和末端的不连续性，随着帧数的增多其误差也会变得越来越大，并且当截断非周期信号时还会出现频谱泄露^[45]的问题，因此通常需要通过加窗函数与原始




图 2-2 本文的研究思路

Fig. 2-2 The research idea

信号的相乘来得到周期信号，并由此增加帧与帧之间的连续性。常用的加窗函数有矩形窗和汉明窗，其中矩形窗的公式为：

$$w(n) = \begin{cases} 1, & 0 \leq n \leq (n-1) \\ 0, & n = \text{else} \end{cases} \quad (2-1)$$

汉明窗的公式为：

$$W(e^{jw}) = e^{-j\mu \frac{N-1}{2} w} \frac{\sin\left(\frac{wN}{2}\right)}{\sin\left(\frac{w}{2}\right)} \quad (2-2)$$

2.2.2 时域分析

(1) 短时能量特征

音乐信号是随时间而变化的，其能量也是随时间而变化的。对于音符的起始点通常都会伴随着音乐能量上的急剧增长，并且一段音乐的能量通常与唤醒价值有关。对于信号的能量特征，需要对其进行分帧、加窗得到长度为 N 的音频序列后进行计算，其计算公式为：

$$E_n = \sum_{m=n}^{n+L-1} x^2(m) \quad (2-3)$$

也可以计算短时幅值来代替短时能量，公式为：

$$M_n = \sum_{m=n}^{n+L-1} |x[m]| \quad (2-4)$$

短时能量特征的一个变异特征是利用心理声学的特点，对其取对数即可以简单地模拟人耳对音乐的响应程度。如图 2-3 所示，从上到下分别是巴赫的 D 小调大提琴组，巴赫的 G 大调大提琴组，从 QQ 音乐上检索的相对舒缓的歌曲和相对欢快的歌曲，以 200 的帧长和 80 的帧移，使用汉明窗进行分析提取的。通过对原始音频波形和短时能量波形的可视化分析，可以发现相对舒缓歌曲的短时平均能量远小于相对欢快的歌曲。




图 2-3 音乐的波形以及对应的短时能量波形

Fig. 2-3 Waveform of music and corresponding short-term energy waveform

(2) 过零率

过零率 (Zero Crossing Rate, ZCR) 是一种直观的计算基频的方法，对于音乐来说基频是频率最低的纯音，且强度最大，决定着整个音乐的音高，由此

可通过 ZCR 算法来检测音高。过零率是通过每帧内信号穿过零轴次数和平均值的标准偏差进行计算的，其计算公式为：

$$Z_{\hat{n}} = \frac{1}{2L} \sum_{m=\hat{n}-L+1}^{\hat{n}} |\text{sgn}(x[m]) - \text{sgn}(x[m-1])| \tilde{w}[\hat{n}-m] \quad (2-5)$$

如图 2-4 所示，通过可视化之后可以发现相对欢快歌曲的平均过零率最高，相对舒缓歌曲的标准差相对较小。从这个结果来看，过零率对分析音乐的情感具有一定的参考价值。




图 2-4 短时平均过零率的波形

Fig. 2-4 Waveform of short-time average zero crossing rate

2.2.3 频域分析

通过对时域上的非周期信号 $f(t)$ 是很难分析得到相关的特征信息，因此通常需要对原始的音频信号进行变换，对数据进行压缩并提取更高级别的信息。其中最基本的变换就是傅里叶变换（Fourier Transform, FT），通过 FT 就可以得到一段音频的频谱，其关系如图 2-5 所示，通过该图可以了解到音频信号是由不同频率的正弦波所叠加组成的。




图 2-5 信号的时域与频域关系图

Fig. 2-5 Time domain and frequency domain relationship of the signal

然而理论上的傅里叶变换是对连续信号进行分析的，无法在计算机上使用。在实际的计算中需要使用离散时间傅里叶变换（Discrete Time Fourier Transform, DTFT）对采样到的数据进行分析。对连续音频信号 $x(t)$ ，通过采样将其离散为 $x[n]$ ，并对 $x[n]$ 进行 DTFT，其计算公式为：

$$X^f(\theta) = \sum_{n=-\infty}^{n=+\infty} x[n] \cdot e^{-j\theta n} \quad (2-6)$$

其中： n 为采样点序列号， θ 是单位为弧度或采样的数字角频率。其变换后的结果虽然在时域上是离散的，但是在频域上依然是连续的，因此需要在 ω 轴上（ $0 \leq k \leq 2\pi$ ）对其均匀采样得到其离散频谱：

$$\theta[k] = \frac{2k\pi}{N}, 0 \leq k \leq N-1 \quad (2-7)$$

其中： N 为时窗长度，采样后的数字频率 θ 可表示为离散数字频率 $\theta[k]$ 。进而就可以得到离散傅里叶变换的公式：

$$X^d[k] = \sum_{n=0}^{n=N-1} x[n] \cdot e^{-j\frac{2\pi kn}{N}}, 0 \leq k \leq N-1 \quad (2-8)$$

式中： $X^d[k]$ 是对时域上 $x[n]$ 的 N 个离散点 DFT 的结果。图 2-6 显示了一段音乐的频谱，从上到下分别是巴赫的 C 小调大提琴组、D 小调大提琴组、G 大调大提琴组的协奏曲。通过其频谱图可以识别出构成音乐的主要频率成分和每个频率的振幅，以及音乐中的主要音调成分。通过振幅可以表示音乐中的响度，并且从图中也可以了解到，一段音乐有多个明显的峰值，这也说明音乐的和弦是由不同的音所构成的。




图 2-6 音频频谱图

Fig. 2-6 Audio spectrogram

2.2.4 时频分析

时频分析可以同时从时间方向和频率方向对音频信号进行分析研究，能较好的呈现出信号频率随时间变化的瞬态特征，进而提高对音乐上的识别。

(1) 短时傅里叶变换

对于 DFT，它是对全局的一种变换，是对一段时间内的平均频率特性。由公式(2-7)不难看出如果增加频域分辨率就会降低时域上的分辨率，反之亦然。对于此缺陷，可以引入短时傅里叶变换（Short Time Fourier Transform, STFT），其原理如图 2-7 所示。




图 2-7 STFT 的原理图

Fig. 2-7 Schematic diagram of STFT

从图 2-7 中可以了解到，STFT 通过设定窗口的大小和步长，在时域信号上进行滑动，在对应的每个窗口内分别进行傅里叶变换，最后再拼接起来，这样就形成了频率随时间变化的数据，构成时间和频率联合分布的二维表示，STFT 的公式为：

$$S(m, k) = \sum_{n=0}^{N-1} x(n + mH)w(n)e^{-i2\pi \frac{kn}{N}} \quad (2-9)$$

通过计算 STFT 的平方便可以创建其时频图，如图 2-8 所示，其中窗函数选择了长度为 128 的汉宁窗，时频图中可以通过第三轴的不同颜色来代表声音的强度。对于音乐的情感分析来说，由于他综合了时域和频域上的特性，因此能够更有效地表示当前的信息。从文献[46]中也可以了解到，此语谱图作为特征的输入，在音乐的情感预测上具有一定的效果。




图 2-8 STFT 的时频图

Fig. 2-8 Time frequency diagram of STFT

(2) Mel 频率倒谱系数

从早期的文献[47]中可以了解到，Mel 频率倒谱系数（Mel Frequency Cepstrum Coefficient, MFCC）是基于人耳听觉特性提出来的。音调是人类感知的东西，在物理学中音调和频率是相同的。然而，人耳能感受到的频率范围是在 20Hz 到 20000Hz 之内，对于超出此频率范围内的信号上人耳就会自动滤波掉此信息，无法感知到。因此在频域上的主观感知是非线性的，而 STFT 的频谱图中频率和时间是呈线性关系的。针对这一问题便发明出了梅尔滤波器组，可以在不改变频率的情况下改变音调的强度，这意味着需要考虑对声压的强度，也就是响度。通过 Mel 频率可以显示在特定频率和特定强度下听到的音高，它与 Hz 形成非线性的对应关系，其对应关系为：

$$\text{Mel}(f) = 2595 \times \lg \left(1 + \frac{f}{700} \right) \quad (2-10)$$

由公式(2-10)中可以了解到 Mel 频率随着频率的提高其计算精度也会随之下降，这也对应着人耳对低频音调有着高敏感度的特点。

在实际的应用中基于 MFCC 的这种特性通常只使用低频的 MFCC，并且

它的图像表示常被深度学习领域中使用去分析音频，也取得了较好的结果。其 Mel 谱图就是一个在梅尔标度下转换 STFT 的时频图，是与若干个梅尔滤波器组的点乘下得到的，如图 2-9 所示，其中 y 轴显示的是 Mel 频率，第三轴通过不同的颜色显示了声音的强度，与图 2-8 相比可以发现在低频下有明显的差异。




图 2-9 Mel 谱图

Fig. 2-9 Mel spectrogram

(3) 常数 Q 变换

常数 Q 变换 (Constant Q Transform, CQT) 变换和 MFCC 类似，也是一种从线性频谱到非线性频谱的一种转换。与 MFCC 不同的是它是一种指数分布规律的时频变换算法，是基于 $\log_2$ 为底的。从之前的乐音理论分析中可以了解到，同一的高八度音的频率是低八度音的两倍，也就是说在音乐中的声音都是以指数分布的形式存在的。而 CQT 恰好满足这个特性，通过 CQT 变换可以直接得到音乐信号在各个音符频率处的振幅值，因此常用于音乐方向的研究上。同时也意味着在低频下 CQT 比 DFT 具有更高的频率分辨率和更低的时间分辨率，如图 2-10 所示。由文献[48]中可以了解到，CQT 在计算频率系数上类似于 DFT，在 DFT 中，中心频率之间的间隔是恒定的，在 CQT 中，中心频率是按指数规律分布的，其中心频率计算公式为：

$$f_k = f_{\min} \cdot 2^{\frac{k}{B}} \quad k = 0, 1, 2, \dots, K-1 \quad (2-11)$$

其中：B 是每八度频率带的个数，对于有限长序列 $x(n)$ 的 CQT 变换为：

$$X^{\text{CQT}}(k) = \frac{1}{N_k} \sum_{n=0}^{N_k-1} x(n) w_{N_k}(n) e^{-i \frac{2\pi n Q}{N_k}} \quad (2-12)$$




图 2-10 CQT 谱图

Fig. 2-10 CQT spectrogram

2.3 本章小结

本章从乐音理论角度出发，通过乐音信号频率与光波长之间的规律，建立了色彩与音乐之间所对应的关系。然后通过现有的音频信号处理技术，用不同的方法对不同的音乐进行了特征提取，并通过可视化的方法进行了观察和分析，以便为后续章节提供相应的理论基础和技术支持。

第3章 基于时频分析的音乐可视化实验平台的设计

本章通过上一章节中的音级与色彩之间的关系，研究并设计了一种内嵌微处理器的色彩音乐播放装置，并详细介绍了硬件的搭建以及软件的设计过程。

3.1 需求分析

音乐可视化研究是基于对音频信号进行时域采样，获得采样到的音频信号的时域数据，并通过对音频数据进行频谱转换，获得其频谱数据。因此为了顺利展开实验，搭建了基于嵌入式的实验平台。该平台可以对音频信号进行采样、分析、输出频谱图，并通过 PWM 控制显示混光色彩，其系统的总体框图如图 3-1 所示。




图 3-1 系统整体框图

Fig. 3-1 Diagram of the system

3.2 硬件系统总体设计

本系统的主板是由多个模块组成的，包含微处理器 IAP15W4K61S4 芯片，

由 CH378 芯片^[49]控制 U 盘和 SD/TF 卡的接口板，由 VS1003 芯片作为解码器的音频解码板，双路音频信号放大采集电路模块，串行通信接口模块，LCD 显示模块，LED 数码管显示模块，键盘模块以及多路 PWM 驱动 RGB-LED 混光模块等，如图 3-2 所示。




图 3-2 系统电路板

Fig. 3-2 System circuit board

实验是在嵌入式平台上进行的，首先需要通过 CH378L 接口芯片读取 U 盘的音频数据，进行音频的文件操作，然后通过 SPI 总线将音频文件传输给 VS1003 芯片进行音频的解码。解码完成后输出音频信号并驱动音箱，实现音乐的播放。同时音频信号经过放大器和滤波器，传送到微处理器的 A/D 转换通道并通过 PWM 输出驱动 LED 发光管，通过设置红 (R)，绿 (G)，蓝 (B) 不同的占空比实现 RGB-LED 混光效果。

3.2.1 双处理器电路设计

系统在播放音乐的过程中除了要进行音频信号的采样、频谱分析、中断处理程序、音级识别、LCD 上实时显示音频信号的频谱图、PWM 驱动实现 RGB-LED 的混光显示以外，还要保证音频数据流以稳定的速度传送到 VS1003

解码器。对此 MPU 的工作负荷非常大，单处理器系统将难以实现以上的需求。为了保证音乐播放的流畅，同时还要实时地进行音乐的可视化展现，就要统筹考虑系统的工作调度和时序安排，并由此设计了双处理器系统，电路接口如图 3-3 所示。




图 3-3 双处理器之间的电路接口

Fig. 3-3 Circuit Interface between Dual Processors

其中处理器 P1 中的锁存器 U1 是数据的输出端口，负责将数据从处理器 P1 发送到处理器 P2，锁存器 U2 负责将数据从处理器 P2 发送到处理器 P1。信号 P1-W 是高电平有效信号，表示处理器 P1 将数据写入到处理器 P2 中。信号 $P2-\overline{R}$ 是低电平有效信号，表示处理器 P2 从处理器 P1 中读取到数据。D 触发器 A 显示处理器 P1 和处理器 P2 的端口状态，显示锁存器 U1 是保持数据还是为空。为了给处理器 P1 发送数据，P1-W 需要变成高电平，此时数据将会锁存在锁存器 U1 中，D 触发器 A(Q) 的状态将变为 0。当处理器 P2 通过读取 ($P2-\overline{S}$ 变为低电平) 来检查其在端口中的状态时，如果数据的最高有效位 (Q7) 为 0 则表示处理器 P1 进入到锁存器 U1 中，处理器 P2 将会读取数据

($\overline{P2-R}$ 变为低电平)并通过检查 D 触发器 A(Q)的状态可知其状态变为 P1,即表示锁存器 U1 为空。此时处理器 P1 会得到其状态(D7 为 1)并可以再次发送数据。处理器 P2 向处理器 P1 发送数据的过程类似,只需要注意,表示锁存器 U2 的状态数据 D6 和 Q6 是否保持数据还是为空。

3.3 音频播放程序设计

3.3.1 音频读取模块设计

为了读取 U 盘的音频文件,本系统选择了对 U 盘接口具有良好特性的 CH378L 芯片。此芯片作为微处理器与存储器 U 盘之间的接口,内置了 USB 传输协议控制和 FAT32 文件系统固件,其中 FAT32 文件系统的逻辑框图如图 3-4 所示。




图 3-4 FAT32 文件系统逻辑框图

Fig. 3-4 FAT32 file system logic block diagram

通过封装底层以及应用层上的函数,使用户可以直接调用 API 接口来实现。另外 CH378L 芯片在 CH375 芯片的基础上额外添加了 20k 的数据缓冲区,且不仅可以应用于 U 盘接口,还可应用于 SD/TF 卡接口,并且 CH378L 和位处理器之间的并行数据接口在读取数据上具有高效的性能。对 U 盘进行操作时,无需了解 USB 通信协议或文件系统,只需要通过 CH378L 的命令便可以进行操作,其接口电路如图 3-5 所示。CH378 的并行接口引脚包含地址信号 A0、片




Fig. 3-5 USB flash disk and SD card connection circuit

当微处理器与 CH378L 通过并口的方式连接时，需要将 CH378L 的状态端口 INT#置为 0，并发出中断。

3.3.2 音频采样模块设计

通过 CH378L 芯片读取音频文件后需要将其进行解码才能实现音频的播放以及采样。对此本系统选择了 VS1003 芯片作为解码芯片,此芯片的优势在于通过简单的操作来完成高效的功能,并且价格非常低廉,其原理图如图 3-6 所示。




Fig. 3-6 Schematic diagram of VS1003

VS1003 和单片机是通过串行外设接口 (Serial Peripheral Interface, SPI) 总线进行的数据传输, 当 VS1003 传送数据的时候需要采用串行数据接口 (SDI) 的形式来传送命令指令, 接收数据时需要采用串行控制接口 (SCI) 的形式来传送数据信息, 并通过数据传输的 16 位寄存器来控制其读写操作。VS1003 接口电路有两个音频输出声道并驱动两个扬声器。其中一个音频声道信号的放大电路为同相放大器, 其放大系数为 $A=1+R_1/R_2=1.5$, 电路如图 3-7 所示。




图 3-7 音频信号放大电路

Fig. 3-7 Amplifying circuit for audio signal

读取存储器上的音频信号之后, VS1003 将会对信号进行解码, 然后通过 D/A 转换器将解码出的数字信号转换成模拟信号, 并从 VS1003 接口板输出的模拟信号 V_i 作为放大器的输入信号, 实现了对 VS1003 双路音频输出信号的放大, 并通过低通滤波实现了音乐的播放。与此同时放大器输出的模拟信号传送至微处理器的一个 A/D 转换通道, 实现了 A/D 采样。在此音频数据流需要以稳定的速度反馈到 VS1003 芯片, 否则播放音乐时将会产生故障或停止。为了完成 VS1003 的解码步骤以及音乐的播放和采样, 首先需要对 VS1003 模块和 SPI 总线进行初始化。然后通过设置 SDI 的数据模式, 将从 CH378L 读取的音频文件数据流传送到 VS1003 芯片, 通过其自动的格式识别技术对音频文件进行解码。数据的传输是通过判定中断引脚 DREQ 来进行的, 当中断引脚 DREQ 置为 1 时就可以发送至少 32 字节的音频数据到 VS1003, 其过程中为了保证音频数据流的流畅性, 发送完数据之后需要将中断引脚置为 0, 然后继续判断数据缓冲区内的音频数据大小, 当少于 32 字节时就需要将 DREQ 置为 1 并继续将数据发送到 VS1003 中, 最后通过内部的 D/A 转换器输出模拟信号, 如此反

复直到播放完整的一首歌。

3.3.3 混光模块设计

混光效果可以由 RGB-LED 混光技术来实现。由于 LED 灯对电路中的电流变化敏感，非常适用于混光电路中的应用，通过混合 LED 发射的不同波长的光，可形成多种颜色。为了形成多种颜色，需要控制每个 LED 灯的亮度进行调节，而调节的细腻度与照明驱动系统的灰度有关。灰度等级越高，说明照明系统的显示越细腻，色彩越丰富，相应的控制系统也就越复杂。考虑到计算机控制的精度和灵活性，本系统采用脉冲宽度调制（Pulse Width Modulation，PWM）对 LED 进行控制。PWM 驱动 RGB-LED 的混光电路，选择红（R），绿（G），蓝（B）作为发光管的光源，使 LED 通过控制定时器和中断函数产生的 PWM 方波的占空比，驱动 R，G，B 三种 LED 发光管并进行亮度的混合，进而形成混光效果，其驱动电路的原理如图 3-8 所示。




图 3-8 RGB-LED 混光模块原理图

Fig. 3-8 RGB-LED light mixing module schematic

LED 是由 NPN 三极管进行驱动的，由于红光，绿光以及蓝光在电路上需要导通不同的电压，因此可通过调节其极限电阻来实现相同 RGB 值下的均匀亮度。但是在实际应用中，三种 RGB-LED 在传导过程中会使发光管导通不同

的压降，从而在相同条件下所导致的亮度也会有差异，因此需要对软件进行修改，使混光效果达到预期的效果。在软件上为了使用 PWM 驱动，需要配置单片机的可编程计数器阵列（Programmable Counter Array, PCA）模块，并通过设置 CCAPMn 寄存器，将其工作模式设置为 PWM 的方式，其流程图如图 3-9 所示。




图 3-9 PWM 控制 LED 混色软件流程图

Fig. 3-9 The software flow chart of LED mixed color with PWM control

在系统的控制下使三种颜色具有 256 级灰度并任意混合，产生 $256 \times 256 \times 256$ （即 16777216）种颜色，进而实现丰富的混光效果。在此需要注意的是，为了确保人的肉眼感受不到 PWM 脉冲，PWM 信号的频率必须高于 100Hz，其中最大 PWM 频率取决于电源启动和响应时间。

3.4 其他模块设计

3.4.1 键盘模块设计

对于音乐的播放，需要控制键盘的按键进行操作。作为输入设备，采用了高精度的 ADC 键盘，它可以对按键进行单一扫描以及对组合按键进行检测。ADC 键盘利用电容让按键按下时消除了因抖动产生的干扰，并通过导通不同的电路来获取不同的分压值，由此来分辨出具体是哪个按键被按下。为了降低占用的 I/O 口资源，采用 ADC0 端口即单片机的 P1.0 口作为四个按键的输入端口。当系统提供电源时，系统将会初始化所有程序，并进入音乐的播放模式。用户可以通过四个按键来操作并选择音乐，进行播放或者暂停。

3.4.2 LCD 显示模块设计

LCD 显示模块可以通过采样到的音频数据进行频谱分析，在播放音乐的同时可以实时地展现出其频谱图，并且通过可视化频谱数据可以验证此系统的可靠性。在 LCD 的选择上本系统采用了具有低功耗，且稳定的 12864 液晶显示屏作为输出口。

3.5 本章小结

为了能够顺利的完成实验，本章详细地介绍了所需要的硬件平台以及技术支持，通过分析完成了对每个模块的设计与搭建，实现了各个模块间的相互通信。

第4章 基于音级识别的音乐可视化系统

4.1 算法分析与设计

4.1.1 快速傅里叶算法

从第二章中的分析可知，如果确定了一个音级的频率，便可以得到相应的颜色。因此就有必要引入傅里叶算法，对于第二章分析的傅里叶算法中可知每计算一个 $x[k]$ 值时要进行 N 次复数相乘和 $(N-1)$ 次复数相加，因此完成全部 DFT 运算需要接近 $O(N^2)$ 次复数算术运算，当 N 较大时会导致计算机的计算速度慢，有时甚至是不能接受的。在嵌入式系统中为了实时地处理信号，有必要引入高效的算法来降低计算复杂度。

令 $W_N^{nk} = e^{-j2\pi nk/N}$ ，可知旋转因子 W_N^{nk} 是一个周期函数，根据欧拉公式， W_N^{nk} 可展开为：

$$W_N^{nk} = \cos(2\pi nk / N) - j \sin(2\pi nk / N) \quad (4-1)$$

则 DFT 可定义为：

$$X(k) = \sum_{n=0}^{N-1} x(n) \cdot (\cos(2\pi nk / N) - j \sin(2\pi nk / N)) \quad (4-2)$$

由此可知，DFT 后的第 k 个点对应的是一个复数。并通过它的周期性和共轭对称性，可将 DFT 的运算量从 N^2 减少到 $N * \log_2 N$ ，这些降低复杂度的算法统称为快速傅里叶变换（Fast Fourier Transform, FFT）。点数越大，FFT 对运算量的改善就越明显，如表 4-1 所示。

表 4-1 FFT 与 DFT 运算量比较
Table 4-1 Comparison of FFT and DFT operations

数据长度 N	原始		FFT	
	乘法次数	加法次数	乘法次数	加法次数
16	256	240	32	64
64	4096	4032	192	384
256	65536	65280	1024	2048
1024	1048576	1047552	5120	24576

为了实现 FFT，需要在嵌入式系统上使用时域抽取法（DIT）技术。具体的实现是以 2 为基（也称基-2）的。由于基-2 DIT-FFT 算法的计算量最小，因此非常适用于嵌入式微处理器系统的频谱分析。该算法将 N 点序列分解为两个 $N/2$ 点序列，进而通过计算这两个短序列的 DFT 得到原 N 点序列的 DFT。在这里主要讨论了幅频特性，其对应的幅值为：

$$A[m] = \sqrt{(\text{Re}_m^2 + \text{Im}_m^2)} \quad m = 1, 2, \dots, N/2 - 1 \quad (4-3)$$

幅值是由音频信号的实部和虚部构成的，可以通过蝶形运算输出。蝶形运算中的输入就是输出的反比特顺序，因此需要将数据的低位通过计算机处理为正序，为了让单片机减少其计算量，可以利用傅里叶变换的对偶性来建立反比特顺序表，进而实现对计算量的优化，提高系统的运算效率，如表 4-2 所示。

表4-2 N=8时的反比特序

Table 4-2 N=8 Code position sort

自然序顺序	二进制	反比特	反比特顺序
0	000	000	0
1	001	100	4
2	010	010	2
3	011	110	6
4	100	001	1
5	101	101	5
6	110	011	3
7	111	111	7

在嵌入式系统中该算法可以通过 KeilC51 环境下进行编写，将变换后的结果 $X[N]$ 分成前半部分和后半部分。前部分存放实部（Re），后部存放虚部（Im）。结果按 $\text{Re}_0, \text{Re}_1, \dots, \text{Re}_{N/2}, \text{Im}_{N/2-1}, \dots, \text{Im}_2, \text{Im}_1$ 的顺序来存储。

4.1.2 基于时频分析的改进的音级识别算法

FFT 相较于 DFT 在计算速度上大幅度的减小了单片机的压力，然而 FFT 本质上还是一种线性变换，无法反映人的听觉感知。在低频下有着较低频率分辨率的缺陷，并且乐音是由很多种属性构成的。需要通过第二章分析过的标准音级或和弦的频谱进行比较，因此对于播放中的音乐仅通过 FFT 是无法准确的获得所需的音级频率分量。从图 2-6 中也可知一段音乐含有多种显著的频率峰

值,那么这一段音乐该对应哪种颜色也是一种问题,如果把这些多种音级的频率分量对应的颜色混在一起,也可以产生另一种颜色,但是在效果上并不是很好,并且在嵌入式系统上比较难以实施,效率低。因此如何提取出有效的频率成分为此系统的关键。

对此,从第二章中的分析中可以了解到,对于以 $1: \sqrt[12]{2}$ 频率之比构成的十二平均律来讲,CQT 无疑是识别音级的最佳选择,然而 CQT 需要庞大的计算量,无法满足于嵌入式系统上实时处理的需求,因此本章提出了一种改进的算法,以 FFT 为基础,以 STFT, MFCC 以及 CQT 算法的思路结合文献[50]做出了改进,在音级高识别率的前提下提取出少而精的频率分量系数,既能满足计算上的效率,同时也可以提高色彩与音乐上的匹配程度,呈现出不一样的可视化效果。

第一步,首先需要对音频文件进行采样,由于得到的音频信号大多数都是连续的信号,无法进行分析。因此需要对连续信号进行采样得到离散信号。为了使信号 $f(t)$ 采样后不丢失信息,根据奈奎斯特定理,采样频率 f_s 必须大于最大频率 f_m 的两倍,即 $f_s \geq 2f_m$ 。由于人耳听觉可分辨的声音信号最大频率为 20KHz,设 f_m 为 20KHz,根据奈奎斯特定理 f_s 应为 40KHz,考虑到一定的余量,本系统的采样频率 f_s 设置为 44KHz,也就是说每次的 A/D 转换时间要控制在 $22.7\mu s$ 。并且还需要考虑取样点 N 、A/D 转换时间、 f_s 、 f_m 和采样周期 T_s 等,以保证理想的效果,如图 4-1 所示。采样应从音频信号的交替分量(如 t_2)开始进行,而不是在直接分量(t_1)下进行。采样过程从 t_2 开始,以 44KHz 的频率下采样 N 次后在 t_3 结束,构成了一组的采样。两组 A/D 采样间隔持续 NT_s 时间长,约为 200~500ms,在这段时间里需要完成音频文件的读取,将输入的音频数据进行解码。

第二步,将一组采样数据(N 点)中的最大值设置为 1,消除信号数据中最大值的差异,完成数据的初始归一化。

第三步,对信号进行分帧加窗,其中窗函数选用汉明窗。

第四步,对每 256 个点进行基-2 DIT-FFT 转换成频谱数据,由于对称性选取左右任意一半。

第五步,进行分段平均,它可以表示数据信号的基本形状,其算法如下所示。首先对序列 $X(k)$ 进行均匀分段:

$$S = \frac{M}{L} \quad (4-4)$$

其中: L 表示分段的长度, M 表示序列 $X(k)$ 的长度。然后计算每个子段序列




图 4-1 音频信号采样

Fig. 4-1 Audio Signal Sampling

$F(r)$ 的平均值:

$$Z(v) = \frac{1}{L} \sum_{r=1}^L F_v(r), \quad 1 \leq v \leq S \quad (4-5)$$

第六步, 重复第二步, 对数据进行最终归一化。

第七步, 通过计算与音级库中的欧氏距离来计算特征空间中两个向量之间的相似程度, 找出最小距离的音调并输出, 欧式距离的计算公式为:

$$E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2} \quad (4-6)$$

4.2 系统测试

首先对关键的系统硬件电路进行调试, 确保每个组件和模块的正常工作。软件部分采用 C 语言对相应的功能进行编程, 并在 keil5 环境下编译。程序主要由系统调试模块, LCD 和 LED 显示模块, 键盘模块, ADC 模块, PWM 模块, FFT 运算模块, 定时器和中断程序模块构成。

4.2.1 音频文件读取及播放测试

为了保持音乐的稳定播放，单片机需要通过 CH378 得到 U 盘的音频数据，然后将音频数据流以恒定的速度发送给 VS1003 进行解码并送出音频信号，进而播放音乐。由于 VS1003 里的数据缓冲区为 32KB，因此 MPU 每次将传送 32KB 大小的数据到 VS1003 后检测 DREQ，当它变为空时会把信号 DREQ 至高，微处理器就会通过 SPI 总线给 VS1003 发送至少 32KB 的数据。此时为了让音乐不断地运行直到播放完成，需要不间断地读取音频数据并进行不断地采集，进而保证音乐的流畅性。当播放音乐时可通过串口助手显示其信息图，如图 4-2 所示，系统运行正常。



图 4-2 串口调试信息

Fig. 4-2 Serial port debugging information

4.2.2 音频采样及频谱分析测试

为了确保本系统的可靠性，首先对采样到的音频数据进行了频谱分析。音频的采样是在音乐播放的同时实时进行的过程，为了避免音频数据精度的失真，

本系统以原始音频文件的采样频率进行了重采样，其采样频率为 44.1KHz，并通过多次实验，每组的采样样本数选取了 512 个点。通过串口助手可以实时地显示其采样到的每组音频数据以及其频谱分析后的数据，如图 4-3 所示。




图 4-3 音频数据

Fig. 4-3 Audio data

部分四组数据如表 4-3，4-4 所示。

表 4-3 采样数据

Table 4-3 Sampling data

序列	1	2	3	4	...	509	510	511	512
第一组	446	447	451	453	...	441	455	445	449
第二组	465	459	452	452	...	455	460	451	467
第三组	449	447	444	452	...	453	449	456	448
第四组	450	447	441	448	...	446	444	440	445

表 4-4 频谱数据

Table 4-4 Spectrum data

序列	1	2	3	4	...	252	253	254	255
第一组	156	145	114	249	...	129	71	62	47
第二组	150	121	53	17	...	53	82	121	154
第三组	53	128	152	199	...	9	53	128	22
第四组	114	96	142	233	...	110	74	75	76

对其数据保存后通过 MATLAB 软件对采样到的数据同样进行了频谱变换，并与本系统的数据进行了比较。如图 4-4，4-5，4-6，4-7 所示，显示了部分四组样本的测试结果。




图 4-4 频谱分析对比图

Fig. 4-4 The picture of spectrum analysis comparison




图 4-5 频谱分析对比图

Fig. 4-5 The picture of spectrum analysis comparison




图 4-6 频谱分析对比图

Fig. 4-6 The picture of spectrum analysis comparison




图 4-7 频谱分析对比图

Fig. 4-7 The picture of spectrum analysis comparison

通过比较 MATLAB 平台下的频谱图和本系统的频谱图可以发现其显著的峰值以及其变化规律上基本达成了一致，由此可以进一步验证本系统的可靠性。

4.2.3 音级识别测试

为了提高音级的识别率，需要通过在前章节中基于音级识别的改进的算法来分析并找出合适的 FFT 的长度、段长度的取值组合，以最少的特征提取系数得出最高的识别率，其分析结果如表 4-5 所示。

表 4-5 不同的组合下音级的平均识别率（%）

Table 4-5 Average recognition rate of voice level under different combinations(%)

FFT 长度（点）	分段长度（点）							
	1	2	4	8	16	32	64	128
16	79.38	71.25	43.30	12.30	-	-	-	-
32	80.93	81.00	78.85	45.25	12.30	-	-	-
64	81.50	82.33	82.43	81.25	55.50	12.30	-	-
128	82.22	82.34	84.45	85.40	87.26	61.20	12.30	-
256	82.31	83.45	85.20	86.34	88.30	87.43	64.30	12.30

由此可以判断，当 FFT 的长度为 256 个点，分段长度为 16 个点时其平均识别率最高。

4.2.4 基于音级的可视化展示

当播放一段音乐的时候，系统会根据分析出来的音级特征得到相应的颜色。在实际的应用中可以通过调节三个 PWM 驱动的输出占空比来实现不同颜色的显示。通过示波器可以观察 PWM 输出的驱动波形图，如图 4-8 所示。




图 4-8 PWM 驱动下输出的波形图

Fig. 4-8 PWM driving of waveforms

在 PWM 驱动下控制的色彩响应速度越快，则可以实时的控制任何颜色下的 RGB 混光模式。当播放一段音乐的时候其混光效果如图 4-9 所示。



图 4-9 RGB-LED 混光效果

Fig. 4-9 Effect of mixed RGB-LED light

4.3 本章小结

本章提出了一种基于音级识别的音乐与色彩实时匹配的新方法，通过分析音乐的和弦特性，提取出音乐中相应的有效频率特征，即确定了在该时刻的频率分量，并通过建立好的音乐与色彩的模型，确定了相应的颜色，完成了色彩与音乐的实时匹配。该系统识别的时间不超过 500ms，确保了混光灯的闪烁与音乐的声音保持并发。并且通过最终效果可以表明，本系统达到了预期的结果。

第5章 基于情感识别的音乐可视化系统

基于上一章节的基础上，本章对音乐进行了进一步的剖析。音乐最吸引人的地方之一就是它可以传达情感并调节听众的情绪，然而对于现有的音乐可视化研究，对低层的音乐特征可以进行多维的体现，但是对于音乐的情感等高层特征体现的研究内容是比较缺乏的。大多数的音乐播放器附带的可视化工具在视觉效果上很难传递歌曲所反映的情绪，因此本章通过将情感概念化，利用深度学习，通过分析不同的模型提出了一种改进的模型架构来识别音乐的情感并建立相匹配的可视化效果来进一步增强音乐的视听体验。

5.1 数据集分析

为了实现音乐与色彩上更加匹配，本章加入了音乐的情感色彩，试着对音乐情感进行分析并映射到颜色维度上。然而音乐情感是非常模糊且主观的一种数据，并且通过音乐低层特征上物理参数的差异是难以分析其高层（如情感）概念上的特征。为了识别出音乐的情感，首先需要对情感做出量化或者测量，针对这一问题，在情感模型的选择上采用了 Russel 提出的 Valence-Arousal 维度情感模型，如图 5-1 所示。




图 5-1 Valence-Arousal 情感空间

Fig. 5-1 Valence-Arousal emotional space

其中 Valence 表示情感的正负性，Arousal 表示情感的激活程度，即情感能

量的高低,通过使用 Valence 和 Arousal 的一对值,将情绪放置在四个象限组成的二维空间中。该模型的优点就是把多种情绪简化成了二维的表示方式,通过二维图上的任意一点的数值来表示一种情感状态,这种连续维度观的情感标注符合情感的多样性,因此对于复杂多变的情感来讲,V-A 模型对情感的计算和识别有着重要的意义。

对于数据集,选择了 DEAM^[51]数据集,该数据集包含 1802 首长达 45s 的歌曲,格式是 MP3 文件,并由 Amazon Mechanical Turk 众包工作人员动态地对每半秒的歌曲标注了 Valence 值和 Arousal 值,其范围是-1 到 1。对于此数据集的选择上主要包含以下几个原因,第一个原因是由于本章是基于深度学习的,而深度学习需要大量的数据支撑才能正确的学习特征,对比其他数据集此数据集通过音乐的节选分成了更多的片段,大大的提高了数据集的数量,所以是比较好的选择。第二个原因是此数据集已被其他研究人员们(Cheuk^[52]等人,Dong^[53]等人)使用过,且取得了比较理想的效果,因此可以说是比较安全的选择。第三,从文献[54]和[55]可知启动情绪反应的平均时间约为 8s,而此数据集的注释者们注释之前都先经过 15s 的时间去适应音乐后才开始以半秒的间隔动态地进行注释,并总共切割成了 60 个片段,因此也可以保证此数据集的真实性和音乐与情感之间的实时性。

5.2 基于时频图的模型构建

音乐的情感与很多音乐的属性相关,因此通过选择有效的特征可以提高网络的学习能力。通常音频信号由原始的音频帧序列或者人工提取的特征向量为基础,在各种深度学习的模型中进行分析和研究。相较于传统的机器学习,深度学习的优势在于它是通过从数据中学习进而提取相关的特征,省去了在机器学习中手动提取特征的步骤。音乐的情感是在听音乐时随着时间的推移而积累的过程。由第二章中的分析可知,时频图即保留了时间特征,同时又保留了频率特征,并且根据文献[56]也可以得知时频图包含了原始音频信号的所有物理信息,因此可以将音乐的时频图作为模型的输入,进而分析和预测音乐的情感。与图像处理等领域类似,对于音频通常由多个前馈卷积神经网络和循环神经网络层来增加其建模能力。

5.2.1 卷积神经网络

卷积神经网络(Convolutional Neural Networks, CNNs)是一种为图像分

类开发的高效的算法，在 3D 体积图像分割、场景解析、物体检测等领域中被广泛应用，在音频分析领域中也常与时频图相连，提取音频的有效特征。从文献[57]中也可以了解到，使用时频谱和 CNN 来提取特征以获得很好的结果，甚至优于传统的机器学习算法，无需手动的提取音频特征便可以很好的识别出音乐的情感。本质上，卷积神经网络在内部通过使用卷积对信息进行过滤，CNN 通常由一系列的卷积层和池化层交错组成。卷积层的输入是一个 $m*n*r$ 的矩阵（图像），其中 m 是高度， n 是宽度， r 是通道数。对于卷积层内卷积核的大小通常比输入图像的宽度和高度小几倍，深度可以等于或小于通道数。通常对时域上的原始波形进行一维卷积或者对时频上的图片进行二维卷积。对于卷积后生成的特征映射图通常采用非线性的激活函数来得到最终特征图上的值。然后通过池化层对卷积层计算出的多个特征映射图进行下采样来减少参数数量，后面还可接一个或多个全连接层（Fully Connected Layers, FC）得到其激活值。卷积神经网络的示例图如图 5-2 所示。




图 5-2 卷积神经网络模型

Fig. 5-2 Convolutional neural network model

对于随时间变化的频率分布图来讲使用 CNN 来解决识别问题是无疑很好的选择。

5.2.2 循环神经网络

音乐是随时间变化的信号，在许多类型的音乐中，它们都遵循时间和频率方面的各种约束和复杂的依赖关系，而对于上下文之间的依赖关系上可以通过循环神经网络（Recurrent Neural Networks, RNN）来解决，其结构如图 5-3 所示。




图 5-3 循环神经网络模型

Fig. 5-3 Recurrent neural networks model

该架构对数据序列中的每个元素执行相同的操作，并通过先前的输入和最后的输出来计算下一个输出，这样就可以将以前的信息与当前的信息联系起来，对于处理顺序序列有较好的性能，因此常用于动态回归问题中，其中 RNN 单元的计算公式为：

$$h_t = \tanh(W_h \cdot [h_{t-1}, x_t] + b_h) \quad (5-1)$$

但是由公式(5-1)可知，RNN 的输出依赖于当前的信息，随着时间的推移会失去上下文。因此对于 RNN 长期依赖问题，通常会引入长短期记忆人工神经网络（Long Short-Term Memory, LSTM），LSTM 是 RNN 的一种特殊形式，在 RNN 的基础上 LSTM 引入了细胞来记住长数据序列中的信息，克服了 RNN 中梯度消失和梯度爆炸的现象，其结构如图 5-4 所示。




图 5-4 长短期记忆人工神经网络的基本架构

Fig. 5-4 Long short-term memory basic architecture.

LSTM 主要是对每个单元增加了三个门的设置, 包含输入门、输出门和遗忘门。其中遗忘门的功能主要是决定是否保留或删除之前单元状态的一些信息, 输入门的功能是选择性地记录当前时刻单元状态的信息, 并在输出门中进行输出, 其中遗忘门的计算公式为:

$$f_t = \sigma_g(W_f s_t + U_f c_{t-1} + b_f) \quad (5-2)$$

输入门向量的计算公式为:

$$i_t = \sigma_g(W_i s_t + U_i c_{t-1} + b_i) \quad (5-3)$$

输出门向量的计算公式为:

$$o_t = \sigma_g(W_o s_t + U_o c_{t-1} + b_o) \quad (5-4)$$

$$c_t = f_t \circ c_{t-1} + i_t \circ \sigma_h(W_c s_t + b_c) \quad (5-5)$$

$$h_t = \sigma_h(o_t \circ c_t) \quad (5-6)$$

其中 σ_g 是 Sigmoid 激活函数; σ_h 是双曲正切函数; $\circ$ 是逐元素相乘符号; f, i, o 分别是遗忘门向量, 输入门向量和输出门向量; W, U, b 是则是每个门的权重矩阵和偏置向量。见式(5-2), 对于输入门, 通过前一时刻的输出与当前时刻的输入做加权求和, 并使用 Sigmoid 函数进行处理得到 0 到 1 的值来选择当前输入信息的比例, 即 1 时保留全部信息, 0 时则遗忘全部信息。见式(5-5), 通过遗忘门和输入门来更新当前时刻的细胞状态, 然后由公式(5-6)来决定最后的输出。

5.2.3 自注意力机制

为了保证模型训练的可靠性, 可以在循环网络层之后加入自注意机制层来优化 LSTM 网络。相较于传统的注意力机制, 自注意力机制不仅能获得注意力机制无法获得的源序列与目标序列的依赖关系, 同时还能有效地获得源序列或目标序列本身之间的依赖关系^[58]。它是一个序列编码层, 可以分配权重系数, 并且不会占用大量的计算机内存。当时刻 t 的输入信息与目标信息越相似时, 注意力层在 t 时刻分配的权重则越大, 因此它可以很有效地减少冗余数据的影响, 提取出更有效的音乐情感数据, 其加权特征向量的计算公式为:

$$Attention(Q, K, V) = SoftMax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5-7)$$

其中：作为输入的三个元素 Q ， K ， V 分别是查询序列，键序列和值序列， $\sqrt{d_k}$ 可以调节过大的点成乘结果。在自注意力机制中三个输入取相同的值，通过参数矩阵映射 Q ， K ， V 之后做自注意力，重复多次，最后再将所有结果串联起来，发送到全连接层。

5.2.4 改进的组合神经网络

综上，基于音乐的时序性和连续性，使用单一的神经网络效果会欠佳。神经网络的本质类似于人类的大脑，在实际生活中，人类对音乐的情感感知通常是通过听觉获得音乐的主旋律，然后根据上下文之间联系自动的感应出音乐的关键情感信息。对此受到启发，并针对 CNN 无法分析对时序上的信息，融合了 LSTM 获取上下文序列信息，对于 LSTM 随着时间的推移，在长序列上学习能力下降的缺点上融合了自注意力模块，并综合考虑 Bhattacharai^[59]等人、Han^[60]等人、Panwar^[61]等人、钟智鹏^[62]等人的研究结果，构建了一种改进的组合神经网络 CLSA(CNN LSTM Self Attention)为基础模型，应用于情感识别的回归问题上。为了确保 CNN 架构运行良好，使用了 VGG16，它是一个预训练的 CNN，其中 16 表示 16 个权重层。VGG 的输入大小为 224×224 的 RGB 图像，内核大小为 3×3 。该网络由 13 个卷积层、5 个最大池化层和 3 个全连接层组成，使用 ReLu 和 SoftMax 作为激活函数，其原始架构如图 5-5 所示。




图 5-5 VGG-16 架构的模型

Fig. 5-5 Model of VGG-16 architecture

其中卷积层和池化层的所有权重都被冻结，最后的全连接层没有被冻结可以进行替换，对此主要选择的策略就是进行微调。通过其全连接层将会输出时频图的一维向量特征，然后再通过 FC 层进行降维来减少所需的参数数量，并作为输入反馈到 LSTM 层获取短时间内和长期的依赖关系。对于 LSTM 的输出可以连接到 2 个全连接层来提高整个网络的鲁棒性。然后加入自注意力层提取音乐中的关键特征信息，最后通过全连接层回归预测最终的 Valence 和 Arousal 值，其基本架构如图 5-6 所示。




图 5-6 基于 CLSA 的音乐情感识别的整体架构

Fig. 5-6 The overall architecture of music emotion recognition based on CLSA

5.3 实验与分析

5.3.1 音乐情感识别的评价指标

对于一个连续维度的情感空间，在情感预测上需要求出其坐标值，因此在 V-A 模型的情感预测上它是属于模式识别中的回归问题。回归的输出是连续的，需要找出一个泛化能力好且错误少的模型。回归通常是线性回归或者是多元回归。线性回归是映射一个特征 x 和单个响应 y 之间的关系。多元回归是由多个特征作为输入，响应单个输出。多元回归可以是线性的也可以是非线性的。图 5-7 表示一个线性回归模型的实例。




图 5-7 线性回归模型实例

Fig. 5-7 Example of linear regression model

因此其评价指标与分类问题有所不同，可通过以下的数学公式比较真实值与预测值来评估模型。对于连续的情感回归预测的常用的评价指标有均方根误差（Root Mean Square Error, RMSE）：

$$\text{RMSE} = \sqrt{\sum_{i=1}^n \frac{1}{n} (y_i - \hat{y}_i)^2} \quad (5-8)$$

其中对于给定的 N 个样本中 $\hat{y}_n$ 表示预测值， y_n 表示对应样本的标注值，其值越低，模型的错误越少，性能越好。平均绝对误差（Mean Absolute Error, MAE）也是衡量误差的常用评价指标：

$$\text{MAE} = \sum_{i=1}^n \frac{1}{n} |y_i - \hat{y}_i| \quad (5-9)$$

MAE 类似于 RMSE，也是通过计算实际点和预测点之间的偏差来计算的，区别是在于 MAE 是计算误差的绝对值来获取总误差。另一个典型的评价指标就是 R^2 ，表示观测值和回归模型之间的拟合程度，取值范围一般是 0 到 1 之间，越接近 1 说明拟合的越好，其计算公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (5-10)$$

5.3.2 音频数据的时频处理

虽然深度学习擅长处理原始非结构化的数据，但是通过预先提取有效特征可以提高训练的效率和准确性。首先把 DEAM 音频数据分成了三个数据，即

训练集、验证集和测试集，并采用了 k 折交叉验证，确保三个数据不重叠。最终用测试集来验证改模型的准确性。由于此数据集是从 15s 之后开始注释的，为了匹配每半秒的动态注释原则，舍弃了开始的 15s 音频段。此外为了契合原始的音频数据，对 15s 到 45s 的音频以每半秒的间隔分割为 60 个子段并不重叠。在 2.2 节中提到，MP3 是一种有损压缩格式，那也就意味着 MP3 格式去除了大量的人耳感知不到的冗余信号。而对于 WAV 格式，它是一种无损的原始音频文件，意味着包含更多的音频信息，因此首先将 DEAM 中的 MP3 文件转换为了无损的 WAV 文件。对于 CNN，由文献[63]的结果可知，使用原始音频信号作为特征输进 CNN 的性能远不如频谱图好，并且根据 Deshpande^[64]等人的说法，时频图包含原始音频的所有数据，此外原始音频的处理计算相对更加复杂，因此将原始音频转换为了时频图。并且音乐的情感是通过人耳感知后产生的，因此在时频图的选择上采用了 Mel 谱图和 CQT 谱图作为 CNN 的输入。并结合分析第二章的内容融合了特征工程中常用的统计特征集来加强网络的信息获取能力，进而提高音乐情感的识别能力。从第二章的乐理理论基础中可以知道，和谐与不和谐的音在物理学上有着很大联系，而且跟情感密不可分。通常和谐与积极的情绪相关，而不和谐常与消极的情绪相关。通常，和谐音的每个音调比率有着相关性，对于这种音程理论关系可以精确的应用在 CNN 模型中，通过这一原则可以计算并设计出用于 CNN 中输入的图像特征，并预测音乐片段的情绪。原始音乐样本的采样率是 44100HZ，为了契合原始的音频数据，通过 librosa 工具包将音频文件同样以 44100Hz 重采样并转换为单声道，创建 STFT 谱图，CQT 谱图，Mel 谱图。综合考虑 VGG16 的性能，对于频谱图进行了归一化操作进而生成了尺寸为 224*224 的图像。

5.3.3 对比试验结果与分析

为了验证此模型的可靠性，选择性的对此模型进行了消融，并在 DEAM 数据集上进行了一系列的对比试验，如表 5-1 和表 5-2 所示。 R^2 可以作为模型拟合度的指标，而 MAE 对异常值更敏感可作为精确度的指标，因此在实验中同时使用了 R^2 和 MAE 作为辅助指标来分析。

表 5-1 在 Valence 中各消融模型回归评估指标结果

Table 5-1 Regression evaluation index results of each ablation model in Valence

模型	R^2	MAE
CNN	0.3932	0.2653

续表(5-1)

CNN-LSTM	0.5189	0.1939
CLSA	0.6698	0.1259

表 5-2 在 Arousal 中各消融模型回归评估指标结果

Table 5-2 Regression evaluation index results of each ablation model in Arousal

模型	R2	MAE
CNN	0.4854	0.2923
CNN-LSTM	0.6389	0.1847
CLSA	0.7298	0.1479

从表中可以看出，CLSA 模型在预测 Valence 值和 Arousal 值的性能上均优于其它的模型，也进一步的验证了此模型的合理性。

5.3.4 音乐情感的可视化设计与展示

通过预测出来的 Valence 和 Arousal 值，选择颜色作为主要的视觉表达形式，其原因是音乐情感参数可以与色彩系统相关联，并且音乐情感与色彩有着密切的关系，当音乐令人兴奋时通常会联想到暖色，当音乐暗下来时通常会联想到冷色^[65]。通常黄色代表快乐，蓝色代表悲伤，红色代表愤怒或警觉，绿色代表平静。从 Plutchik^[66]提出的情感色轮中也可以了解到，情绪可以通过颜色来表达，如图 5-8 所示。




图 5-8 Plutchik 的情绪色轮图

Fig. 5-8 Plutchik's mood wheel

从 Plutchik 的色轮图中可以发现, 每种情绪都有不同等级的强度, 并可以通过一种颜色的深浅度来表达, 且相反的情绪在图表上彼此相对。由此可以通过颠倒颜色的离散映射来创建情感到色彩的模型, 对 Valence 和 Arousal 值拟合到颜色空间中的 x, y 的坐标上。对于点 $(-0.5, 0.5)$ 可以映射到红色。点 $(0.5, 0.5)$ 可以映射到黄色等等。对于中间及其他点的颜色可以根据与参考点的欧式距离变换来进行计算坐标值所对应的 RGB 值, 进而获得与情感相关的特定的颜色。其部分 V-A 值以及对应的 RGB 值如表 5-3 所示。

表 5-3 V-A 值与 RGB 值的对应表

Table 5-3 Corresponding Table of V-A Value and RGB Value

V-A 坐标值	RGB 值	颜色
$(-0.5, 0.5)$	$(255, 0, 0)$	红色
$(0.5, 0.5)$	$(255, 255, 0)$	黄色
$(-0.5, -0.5)$	$(0, 0, 255)$	蓝色
$(0.5, -0.5)$	$(0, 205, 0)$	绿色

其播放效果如图 5-9, 5-10, 5-11 所示, 其中右侧图片中小圆圈则是此刻音乐的 V-A 值以及找出的所匹配的颜色, 左侧则是求出的 V-A 值以及情感属性。




图 5-9 音乐播放效果图

Fig. 5-9 Music playing effect picture




图 5-10 音乐播放效果图

Fig. 5-10 Music playing effect picture




图 5-11 音乐播放效果图

Fig. 5-11 Music playing effect picture

此外此程序还可以连接智能混光灯，进而实现不一样的色彩音乐系统。

5.4 本章小结

本章主要从 CNN、RNN、注意力机制三个基本模型方法中出发，提出了改进的 CLSA 模型，并在此模型的基础上，做了实验与分析，验证了此模型的合理性以及有效性。其次对情感和色彩的关系进行了建模，完成了基于音乐情感到色彩的可视化系统。

结 论

本课题为了实现音乐的可视化,综合运用数字信号处理技术、微处理技术以及人工智能等技术,研发了一种色彩音乐可视化系统,包含基于音级识别的色彩音乐可视化系统以及基于情感识别的音乐可视化系统。对于音级识别的色彩音乐可视化系统是在嵌入式平台上进行的实验,涉及到了多种硬件的搭建以及软件的设计,包括双处理器电路、文件系统模块、音频解码模块以及 PWM 驱动 RGB-LED 混光模块等。并在此嵌入式实验平台上,研制了基于音级识别的色彩音乐播放系统。对于情感识别的色彩音乐可视化系统,综合运用了心理学,音频信号处理技术以及模式识别技术,将分析出的情感映射到了二维空间上并展现出了不一样的可视化效果。本文的工作总结如下:

(1) 为了实现音乐的可视化,首先从音乐理论基础出发,通过其十二平均律的数学规律,将音级频率特性映射到了光波长的特性,完成了基于音级的色彩对应表。然后通过音频信号处理技术,对不同的音乐进行了时域和频域上的可视化分析,为之后的实验奠定了理论基础以及技术支持。

(2) 为了完成基于音级的音乐可视化系统,并考虑到实际的应用需求,首先设计开发了基于嵌入式系统的实验平台,对各个模块的软硬件进行了设计与搭建,包含音频读取模块、音频解码和采样模块、键盘的输入模块、LCD 显示以及 RGB-LED 混光的输出模块等,完成了各个模块间的相互通信,并且为了各个模块间的流畅性以及音乐播放的同时确保色彩的实时性,通过统筹考虑系统的工作调度和时序安排下设计了双处理器系统,并对此平台进行了改进。

(3) 为了实现音级与色彩的匹配,并且为了适应于嵌入式系统,通过前期分析的 STFT、MFCC、CQT 等时频分析算法的基础上做出了改进和优化,为了验证此算法的有效性,通过搭建的平台,进行了实验测试。为了保证音乐播放的稳定性,首先通过串口助手对播放中的音乐进行了测试,保证了音乐不间断读取的同时音频数据不断地被进行采样并实时地进行频谱变换。然后对采样的数据同样的在 PC 机上做了频谱分析,并通过与此系统分析出的频谱数据相比较来验证了此系统的可靠性。为了保证音乐与色彩的相匹配,对采样出的音频数据不断地进行实验以找出合适的参数来识别出音级并做了不断地改进和优化来提高可视化效果。

(4) 为了能更进一步加强色彩音乐的可视化效果,对音乐的高层特征,即音乐的情感进行了进一步的分析。为了实现音乐情感与色彩的匹配,首先通

过研究找出了音乐情感的量化方式，即 V-A 模型。基于此模型找出了可靠的情感数据集，并在此基础上综合利用人工智能技术，提出了一种改进的 CLSA 模型并识别出了音乐在二维情感空间中的坐标值。然后综合考虑心理学的知识，并用科学的方法对此坐标值进行了色彩空间上的映射，展现出了音乐情感与色彩相匹配的音乐可视化系统。

本文在嵌入式系统以及 PC 机上完成了音乐的可视化效果，由于嵌入式系统的低功耗、低成本、便携性、可移植性以及实时性的特点，如果能够结合嵌入式和 PC 机上的实验，此系统将会有更强大的应用空间，如城市景观、舞台灯光、车载氛围灯以及心理治疗等，因此非常具有实际的研究意义和广阔的应用前景。

参考文献

- [1] 常慧娟. 可视化技术对音乐视觉表现的影响[J]. 现代商贸工业, 2016(34): 498-499.
- [2] 刘浩东, 杨洁. 音乐教学设计与面向对象方法的可视化建模[J]. 教育现代化, 2017(15): 107-109.
- [3] Lee J Y, Moon C B, Kim B M. The Color-Music Relationship Direct Modeling Using Machine Learning[C]. IEEE Eleventh International Conference on Ubiquitous and Future Networks (ICUFN), Zagreb, Croatia, 2019: 629-631.
- [4] 李伟, 李子晋, 高永伟. 理解数字音乐——音乐信息检索技术综述[J]. 复旦学报(自然科学版), 2018, 57(03): 271-313.
- [5] 李雨蒙. 交互类声音视觉化的设计表现方法研究[D]. 大连: 大连理工大学, 2019: 38-51.
- [6] 袁有雯. 从数学角度探析音乐的规律性——以巴赫作品为例[J]. 数学教学, 2008(06): 38-41.
- [7] 康宁. 创造美的形象形式和形式主义[J]. 人像摄影, 2015(06): 130-131.
- [8] Lima H B, Santos C G R D, Meiguins B S. A Survey of Music Visualization Techniques[J]. ACM Computing Surveys (CSUR), 2021, 54(7): 1-29.
- [9] Ciuha P, Klemenc B, Solina F. Visualization of Concurrent Tones in Music with Colors[C]. Proceedings of the 18th ACM International Conference on Multimedia, Firenze, Italy, 2010: 1677-1680.
- [10] Lu L, Liu D, Zhang H J. Automatic Mood Detection and Tracking of Music Audio Signals[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2005, 14(1): 5-18.
- [11] Smith S M, Williams G N. A Visualization of Music[C]. IEEE Proceedings Visualization'97, Phoenix, AZ, USA, 1997: 499-503.
- [12] Mörchen F, Ultsch A, Nöcker M, et al. Data Bionic Visualization of Music Collections According to Perceptual Distance[C]. 6th International Conference on Music Information Retrieval, London, UK, 2005: 396-403.
- [13] 李华, 胡春晖, 顾明. 基于实时渲染技术具有水彩画风格的音乐可视化方法[J]. 计算机应用, 2005(03): 729-731.

- [14] Chen C H, Weng M F, Jeng S K, et al. Emotion-Based Music Visualization Using Photos[C]. International Conference on Multimedia Modeling Springer, Berlin, Heidelberg, 2008: 358-368
- [15] Poostchi M, Kamkar I, Mohebbi J. Music Visualization by Means of Comb Filter and Relaxation Time According to Human Perception[M] Soft Computing in Industrial Applications. Springer, Berlin, Heidelberg, 2010: 165-173.
- [16] Gumulia A, Puzon B B, Kosugi N. Music Visualization: Predicting the Perceived Speed of a Composition--Misual Project--[C]. Proceedings of the 19th ACM International Conference on Multimedia, Scottsdale, Arizona, USA, 2011: 949-952.
- [17] Pouris M, Fels D I. Creating an Entertaining and Informative Music Visualization[C]. International Conference on Computers for Handicapped Persons Springer, Berlin, Heidelberg, 2012: 451-458.
- [18] Maekaku T, Kasai H. Music Relationship Visualization Based on Melody Piece Transition Using Conditional Divergence[J]. IEEE Transactions on Consumer Electronics, 2012, 58(3): 1006-1012.
- [19] Yoshihara Y, Miura T. Classifying Polyphony Music Based on Markov Model[C]. International Conference on Intelligent Data Engineering and Automated Learning Springer, Berlin, Heidelberg, 2006: 697-706.
- [20] Fonteles J H, Rodrigues M A F, Basso V E D. Creating and Evaluating a Particle System for Music Visualization[J]. Journal of Visual Languages & Computing, 2013, 24(6): 472-482.
- [21] Soriano A, Paulovich F, Nonato L G, et al. Visualization of Music Collections Based on Structural Content Similarity[C]. 2014 27th SIBGRAPI Conference on Graphics, Patterns and Images IEEE, Rio de Janeiro, Brazil, 2014: 25-32.
- [22] Kim J, Ananthanarayan S, Yeh T. Seen Music: Ambient Music Data Visualization for Children with Hearing Impairments[C]. Proceedings of the 14th International Conference on Interaction Design and Children, Boston, Massachusetts, 2015: 426-429.
- [23] Malandrino D, Pirozzi D, Zaccagnino G, et al. A Color-Based Visualization Approach to Understand Harmonic Structures of Musical Compositions[C].

- 19th International Conference on Information Visualization IEEE, Barcelona, Spain, 2015: 56-61.
- [24] Lee Y, Fathia R N. Interactive Music Visualization for Music Player Using Processing[C]. 2016 22nd International Conference on Virtual System & Multimedia IEEE, Kuala Lumpur, Malaysia, 2016: 1-4.
- [25] Xie Z, Chen Y. Music Visualization Based on the MIDI Specifications for Multidimensional Polyphonic Expression[C]. 2017 4th International Conference on Systems and Informatics (ICSAI) IEEE, Hangzhou, China, 2017: 1250-1255.
- [26] Takahashi T, Fukayama S, Goto M. Instrudiver: A Music Visualization System Based on Automatically Recognized Instrumentation[C]. ISMIR, Chicago, IL, USA, 2018: 561-568.
- [27] Taenzer M, Wünsche B C, Müller S. Analysis and Visualization of Music[C]. International Conference on Electronics, Information, and Communication (ICEIC) IEEE, Auckland, New Zealand, 2019: 1-6.
- [28] 韦岗, 曹燕, 王一歌, 等. 计算机音乐可视化表征谱设计[J]. 现代信息科技, 2019, 3(14): 5-7.
- [29] Li W, Li J. Research on Music Visualization Based on Graphic Images and Mathematical Statistics[J]. IEEE Access, 2020, 8: 100652-100660.
- [30] Liu X. An Improved Particle Swarm Optimization-Powered Adaptive Classification and Migration Visualization for Music Style[J]. Complexity, 2021: 1-10.
- [31] 王晨晨, 杨锦焯, 彭璐, 等. 基于单片机的音乐喷泉设计[J]. 软件, 2020, 41(09): 76-77.
- [32] 杨蕴哲, 李昌禄, 杨业昆, 等. 基于单片机的音乐喷泉设计[J]. 实验科学与技术, 2020, 18(03): 43-49.
- [33] 朱建书. 基于 PLC 的舞台灯光设备智能控制系统[J]. 自动化与仪器仪表, 2022(09): 97-101.
- [34] 曾丽萍, 林泽. 基于 PLC 的舞台灯控制系统及组态监控设计[J]. 工业控制计算机, 2021, 34(10): 126-127.
- [35] Hsiao S W, Chen S K, Lee C H. Methodology for Stage Lighting Control Based on Music Emotions[J]. Information Sciences, 2017, 412: 14-35.

- [36] 费孝峰, 樊嘉杰, 邓亮, 等. 基于深度学习的 LED 车载语音交互氛围灯设计[J]. 照明工程学报, 2020, 31(01): 64-69.
- [37] 龚岱, 颜丽娟. 可视音乐干预联合调序疗法对精神发育迟缓儿童适应行为能力及智能发育的影响[J]. 教育生物学杂志, 2021, 9(02): 129-134.
- [38] Dharmapriya J, Dayarathne L, Diasena T, et al. Music Emotion Visualization through Color[C]. 2021 International Conference on Electronics, Information, and Communication (ICEIC) IEEE, Jeju, Korea (South), 2021: 1-6.
- [39] Malandrino D, Pirozzi D, Zaccagnino G, et al. A Color-Based Visualization Approach to Understand Harmonic Structures of Musical Compositions[C]. 2015 19th International Conference on Information Visualization IEEE, Barcelona, Spain, 2015: 56-61.
- [40] Tsang T, Schloss K B. Associations Between Color and Music are Mediated by Emotion and Influenced by Tempo[J]. The Yale Review of Undergraduate Research in Psychology, 2010: 82.
- [41] Jiang Y, Zhao J. Subjective Evaluation of the Correlation of Pop Music Emotion and Lighting Color[C]. 2019 12th International Congress on Image and Signal Processing, Bio Medical Engineering and Informatics (CISP-BMEI) IEEE, Suzhou, China, 2019: 1-5.
- [42] Liu J, Zhao A, Wang S, et al. Research on the Correlation Between the Timbre Attributes of Musical Sound and Visual Color[J]. IEEE Access, 2021, 9: 97855-97877.
- [43] Sethares W A. Tuning, Timbre, Spectrum, Scale[M]. London: Springer Science & Business Media, 2005: 20-48.
- [44] 刘芳. 为产品涂上和谐的色彩[D]. 合肥: 合肥工业大学, 2009: 3-8.
- [45] 示波器上的频域分析利器——时频域信号分析技术[J]. 中国电子商情(基础电子), 2019(08): 41-42.
- [46] Satt A, Rozenberg S, Hoory R. Efficient Emotion Recognition from Speech Using Deep Learning on Spectrograms[C]. Interspeech, Stockholm, Sweden, 2017: 1089-1093.
- [47] Stevens S, Volkman J, Newman E B. A Scale for the Measurement of the Psychological Magnitude Pitch[J]. The journal of the Acoustical Society of America, 1937, 8(3): 185-190.

- [48] Brown J C. Calculation of a Constant Q Spectral Transform[J]. The Journal of the Acoustical Society of America, 1991, 89(1): 425-434.
- [49] 黄天灵. 基于视觉传达的网页文字色彩自动匹配系统设计[J]. 现代电子技术, 2020, 43(22): 102-105.
- [50] Sumarno L, Iswanjono I. Feature Extraction of Musical Instrument Tones Using FFT and Segment Averaging[J]. TELKOMNIKA (Telecommunication Computing Electronics and Control), 2017, 15(3): 1280-1289.
- [51] Alajanki A, Yang Y H, Soleymani M. Benchmarking Music Emotion Recognition Systems[J]. PloS one, 2016: 835-838.
- [52] Cheuk K W, Luo Y J, Balamurali B T, et al. Regression-Based Music Emotion Prediction Using Triplet Neural Networks[C]. 2020 International Joint Conference on Neural Networks (ijcnn) IEEE, Glasgow, UK, 2020: 1-7.
- [53] Dong Y, Yang X, Zhao X, et al. Bidirectional Convolutional Recurrent Sparse Network (BCRSN): an Efficient Model for Music Emotion Recognition[J]. IEEE Transactions on Multimedia, 2019, 21(12): 3150-3163.
- [54] Bachorik J P, Bangert M, Loui P, et al. Emotion in Motion: Investigating the Time-Course of Emotional Judgments of Musical Stimuli[J]. Music Perception, 2009, 26(4): 355-364.
- [55] Schubert E. Reliability Issues Regarding the Beginning, Middle and End of Continuous Emotion Ratings to Music[J]. Psychology of Music, 2013, 41(3): 350-371.
- [56] Pons J, Nieto O, Prockup M, et al. End-to-End Learning for Music Audio Tagging at Scale[J]. arXiv preprint arXiv:1711.02520, 2017: 1-6.
- [57] Liu X, Chen Q, Wu X, et al. CNN Based Music Emotion Classification[J]. arXiv preprint arXiv:1704.05665, 2017: 1-7.
- [58] 刘志华, 陈文洁, 陈爱斌. 基于自注意力机制时频谱同源特征融合的鸟鸣声分类[J]. 计算机应用, 2022, 42(04): 1260-1268.
- [59] Bhattarai B, Lee J. Automatic Music Mood Detection Using Transfer Learning and Multilayer Perceptron[J]. International Journal of Fuzzy Logic and Intelligent Systems, 2019, 19(2): 88-96.
- [60] Han D, Kong Y, Han J, et al. A Survey of Music Emotion Recognition[J]. Frontiers of Computer Science, 2022, 16(6): 1-11.

- [61] Panwar S, Rad P, Choo K R, et al. Are You Emotional or Depressed? Learning About Your Emotional State from Your Music Using Machine Learning[J]. The Journal of Supercomputing, 2019, 75(6): 2986-3009.
- [62] 钟智鹏, 王海龙, 苏贵斌, 等. 融合 CNN-BiLSTM 和自注意力模型的音乐情感识别[J]. 计算机工程与应用, 2023, 59(03): 94-103.
- [63] Sarkar R, Choudhury S, Dutta S, et al. Recognition of Emotion in Music Based on Deep Convolutional Neural Network[J]. Multimedia Tools and Applications, 2020, 79(1): 765-783.
- [64] Deshpande H, Singh R, Nam U. Classification of Music Signals in the Visual Domain[C]. Proceedings of the COST-G6 Conference on Digital Audio Effects, Limerick, Ireland, 2001, 1(3): 1-4.
- [65] 苏泉林. 基于“主旋律与情绪”的音频可视化产品设计研究[D]. 长沙: 湖南大学, 2019: 12-19.
- [66] Plutchik R. The Nature of Emotions: Human Emotions Have Deep Evolutionary Roots, a Fact That May Explain Their Complexity and Provide Tools for Clinical Practice[J]. American Scientist, 2001, 89(4): 344-350.